

Informe Proyecto 2: PageRank en la Red de Control de Tráfico Aéreo (FAA)

Liz González Isidora Mora Vicente Rodríguez
IMT2230 Álgebra Lineal Avanzada y Modelamiento
Pontificia Universidad Católica de Chile

7 de julio de 2026

Resumen

En este informe se presenta el análisis estructural de la red de control de tráfico aéreo estadounidense (**maayan-faa**) utilizando el algoritmo PageRank. Evaluamos la hipótesis de que, debido a la estructura centralizada de tipo *hub-and-spoke*, los aeropuertos con mayor conectividad directa presentan también la mayor importancia global, aunque existen excepciones clave de nodos con grado moderado que actúan como puentes críticos del sistema de transporte. Los resultados muestran una alta correlación general entre el grado de entrada y PageRank ($r \approx 0,7972$), validando parcialmente la hipótesis y revelando nodos puente con alta relevancia global y baja conectividad directa.

1. Introducción y Contexto (P1 & P2)

La red **maayan-faa** modela el sistema de rutas aéreas sugeridas de la Administración Federal de Aviación (FAA) de Estados Unidos. Los nodos representan aeropuertos o centros de servicio, y las aristas dirigidas ($i \rightarrow j$) corresponden a rutas preferidas recomendadas por el NFDC. Los datos fueron obtenidos del repositorio KONECT (<http://konect.cc/networks/maayan-faa/>), que aloja la red bajo el nombre **maayan-faa** (*Air Traffic Control*); se eligió esta red por cumplir con los requisitos del proyecto (dirigida, con más de 500 nodos y 2 000 aristas) y por tener un contexto real e interpretable.

Cuadro 1: Estadísticas Básicas de la Red **maayan-faa**.

Métrica	Valor
Número de nodos (n)	1,226
Número de aristas (m)	2,615
Grado de entrada medio ($\bar{d}_{\text{in}}$)	2.1338
Grado de salida medio ($\bar{d}_{\text{out}}$)	2.1338
Densidad del grafo	0.001741
Nodos colgantes (out-degree = 0)	143 (11.67 %)
Nodo de mayor grado de entrada	ID 312 ($d_{\text{in}} = 20$)

1.1. Justificación Matemática de la Igualdad de Grados Medios

En cualquier grafo dirigido, cada arista dirigida contribuye exactamente a un grado de salida (d_{out}) de su origen y a un grado de entrada (d_{in}) de su destino. Por doble conteo, la suma de los grados de entrada es igual a la suma de los grados de salida, lo que equivale al total de aristas m :

$$\sum_{i=1}^n d_{\text{in}}(i) = \sum_{i=1}^n d_{\text{out}}(i) = m \quad (1)$$

Dividiendo ambos lados de la ecuación por el total de nodos n , obtenemos la equivalencia de los grados medios:

$$\bar{d}_{\text{in}} = \frac{1}{n} \sum_{i=1}^n d_{\text{in}}(i) = \frac{m}{n} = \frac{1}{n} \sum_{i=1}^n d_{\text{out}}(i) = \bar{d}_{\text{out}} \quad (2)$$

Para la red analizada, este valor es exactamente $\frac{2615}{1226} \approx 2,1338$.

1.2. Motivación y Pregunta de Investigación

Las redes de tráfico aéreo físico suelen exhibir una estructura centralizada de tipo *hub-and-spoke*, donde un número reducido de aeropuertos concentran gran parte de las conexiones, mientras que la mayoría actúa como satélites.

- **Pregunta:** ¿Los aeropuertos con mayor tráfico entrante son también los de mayor relevancia estructural para la red, o existen nodos de grado moderado que actúan como puentes indispensables entre diferentes sectores?
- **Hipótesis:** Esperamos que los nodos con mayor grado de entrada presenten los PageRank más altos. No obstante, postulamos la existencia de nodos de grado de entrada moderado que actúan como puentes de conectividad de la red física nacional, obteniendo un PageRank significativamente superior al predicho por su grado directo.

2. Análisis Exploratorio y Conectividad (P3)

La distribución de grados muestra un comportamiento típico de red de escala libre con un decaimiento severo, concentrándose la gran mayoría de los nodos en grados muy bajos (Figura 1).




Figura 1: Distribución del grado de entrada y del grado de salida (escala log-log).

Se identificaron **143 nodos colgantes** (11.67 % del total). Estos nodos no poseen enlaces salientes, por lo que provocan columnas nulas en la matriz de adyacencia transpuesta H , rompiendo la propiedad estocástica indispensable para la convergencia estable del modelo.

Respecto a la conectividad, la red **no es fuertemente conexa** (434 componentes fuertemente conexas), pero sí es **débilmente conexa** (1 sola componente si omitimos el sentido de las aristas). La falta de conectividad fuerte no representa un problema para el cálculo de PageRank porque la Matriz de Google $G = \alpha S + (1 - \alpha) \frac{1}{n} E$ añade un factor de teletransportación uniforme que garantiza que todas sus entradas sean estrictamente positivas ($G_{ij} > 0$), haciendo que la cadena de Markov sea siempre irreducible y aperiódica.

Cuadro 2: Top 10 nodos por grado de entrada y por grado de salida.

Mayor grado de entrada		Mayor grado de salida	
ID Nodo	d_{in}	ID Nodo	d_{out}
312	20	68	24
68	13	52	22
82	13	44	20
110	13	113	20
109	12	89	18
52	11	187	18
105	11	47	17
135	11	312	17
10	10	604	17
34	10	212	15

El nodo 312 encabeza ambos rankings casi simultáneamente (mayor in-degree y segundo mayor out-degree entre los aquí listados), consistente con su rol de hub principal. En cambio, nodos como el 68 concentran el mayor out-degree de la red (24) sin ser el de mayor in-degree, lo que sugiere que ciertos nodos operan más como distribuidores de tráfico saliente que como destinos concentradores de tráfico entrante.

3. Formulación de la Matriz de Google (P4)

La matriz de hipervínculos $H \in \mathbb{R}^{n \times n}$ se define como:

$$H_{ij} = \begin{cases} 1/d_{\text{out}}(j) & \text{si existe } j \rightarrow i \\ 0 & \text{en caso contrario} \end{cases} \quad (3)$$

Si el nodo j no es colgante, la suma de la columna j en H es exactamente 1, puesto que contiene exactamente $d_{\text{out}}(j)$ entradas con valor $1/d_{\text{out}}(j)$. Para reparar las columnas nulas de los nodos colgantes, construimos la matriz S :

$$S = H + \frac{1}{n} \mathbf{1} \mathbf{a}^T \quad (4)$$

donde $\mathbf{a}$ es un vector indicador tal que $a_j = 1$ si $d_{\text{out}}(j) = 0$ y 0 de lo contrario. Al construir esta matriz en el código, se verificó numéricamente (por ejemplo, utilizando funciones como `np.allclose`) que todas las columnas de S suman exactamente 1. Esto confirma empíricamente que la reparación de los nodos colgantes mediante el vector uniforme $1/n$ fue implementada de forma correcta para evitar la pérdida de probabilidad. Finalmente, aplicamos el factor de amortiguación $\alpha = 0,85$ para formular la Matriz de Google G :

$$G = \alpha S + \frac{1 - \alpha}{n} \mathbf{1} \mathbf{1}^T \quad (5)$$

Justificación de $\alpha = 0,85$: El parámetro α (factor de amortiguamiento) controla el balance entre seguir la estructura real de enlaces de la red y «teletransportarse» uniformemente a cualquier nodo. Un α cercano a 1 hace que el PageRank dependa casi exclusivamente de la estructura de la red (pero la convergencia de la iteración de potencias se vuelve más lenta, ya que la tasa de convergencia es geométrica con razón α). Un α cercano a 0, en cambio, acerca a G a una matriz uniforme, perdiendo casi toda la información estructural de la red. Usamos $\alpha = 0,85$ por ser el valor propuesto originalmente por Brin y Page en el paper fundacional de

PageRank¹, adoptado como estándar de facto en la literatura: ofrece un buen equilibrio entre fidelidad a la estructura real de enlaces y velocidad de convergencia razonable (en nuestro caso, 52 iteraciones para $\varepsilon = 10^{-10}$).

Verificación de la construcción de G : Se verificó numéricamente que:

- H presenta exactamente 143 columnas nulas, correspondientes a los 143 nodos colgantes identificados en el análisis exploratorio (P3).
- Todas las columnas de S suman exactamente 1 (verificado con `np.allclose`), confirmando que la reparación de nodos colgantes mediante el vector uniforme $\mathbf{1}/n$ fue implementada correctamente.
- Todas las entradas de G son estrictamente positivas (mínimo $\approx 1,22 \times 10^{-4}$, consistente con el valor teórico $(1 - \alpha)/n \approx 1,22 \times 10^{-4}$), y todas sus columnas suman exactamente 1, confirmando que G es una matriz columna-estocástica con entradas estrictamente positivas.

Esta última propiedad es la que garantiza, por el Teorema de Perron-Frobenius, que G sea irreducible y aperiódica, asegurando la existencia de una única distribución estacionaria $\mathbf{r}^*$ con $r_i^* > 0$ para todo i , independientemente de la conectividad del grafo original.

4. Iteración de Potencias y Resultados (P5, P6 & P7)

Implementamos el método de la potencia calculando la sucesión de vectores $\mathbf{r}^{(k+1)} = G\mathbf{r}^{(k)}$ hasta cumplir con una tolerancia de convergencia de $\varepsilon = 10^{-10}$. El método converge tras **52 iteraciones**. El decaimiento del error $\|\mathbf{r}^{(k)} - \mathbf{r}^*\|_1$ confirma un comportamiento geométrico, con una tasa de decaimiento promedio de **0.6577**, significativamente menor a la cota teórica superior dada por $\alpha = 0,85$.

Teóricamente, el error en la iteración k decae de forma geométrica siguiendo la relación $\|\mathbf{r}^{(k)} - \mathbf{r}^*\|_1 \approx C|\lambda_2|^k$, donde λ_2 es el segundo autovalor en magnitud de G . Dado que la estructura de la matriz de Google implica que sus autovalores distintos del principal son exactamente α veces los autovalores de S , el valor $\alpha = 0,85$ actúa como una cota superior teórica para la convergencia. El hecho de que nuestra tasa observada sea de 0,6577 indica que el segundo autovalor de S para esta red en particular tiene una magnitud menor a 1 (aproximadamente $0,6577/0,85 \approx 0,77$), lo que permite que el método converja de manera más rápida que en el peor caso teórico.

Al converger, se verifican rigurosamente las propiedades de probabilidad: $\|\mathbf{r}^*\|_1 = 1,0$ y $r_i^* > 0$ para todo i (mínimo valor observado: $\approx 2,13 \times 10^{-4}$). Cabe destacar que, si bien G se construyó de forma densa en la Sección 3 únicamente con fines de verificación teórica, la iteración de potencias no utiliza esa matriz densa: se aprovecha la identidad $G\mathbf{r} = \alpha H\mathbf{r} + \alpha \frac{(\mathbf{a}^T \mathbf{r})}{n} \mathbf{1} + \frac{1-\alpha}{n} \mathbf{1}$, lo que permite calcular el producto matriz-vector utilizando únicamente la matriz dispersa H (con solo 2615 entradas no nulas de un total de $1226^2 \approx 1,5$ millones), evitando construir o multiplicar por la matriz G completa en cada iteración.

¹Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank Citation Ranking: Bringing Order to the Web*. Stanford InfoLab Technical Report.




Figura 2: Curva de convergencia del error $\|\mathbf{r}^{(k)} - \mathbf{r}^*\|_1$ en escala logarítmica, con decaimiento geométrico de razón $\approx 0,6577$.

Verificación de propiedades teóricas de $\mathbf{r}^*$: Se verificó que $\|\mathbf{r}^*\|_1 = 1,0000000000$ y que $r_i^* > 0$ para los 1226 nodos.

Ambas propiedades están garantizadas por la teoría, no son coincidencia numérica:

- $\|\mathbf{r}^*\|_1 = 1$ se conserva en cada iteración porque G es columna-estocástica (cada columna suma 1), por lo que G preserva la suma total de probabilidad: si $\|\mathbf{r}^{(k)}\|_1 = 1$, entonces $\|\mathbf{r}^{(k+1)}\|_1 = \|G\mathbf{r}^{(k)}\|_1 = 1$ también, partiendo de $\mathbf{r}^{(0)} = \mathbf{1}/n$, que ya cumple esta propiedad.
- $r_i^* > 0$ para todo i está garantizado porque, como se estableció en la Sección 3 (P4), todas las entradas de G son estrictamente positivas. Por el Teorema de Perron-Frobenius, una matriz columna-estocástica con todas sus entradas positivas tiene un único autovector propio asociado al autovalor 1, y ese autovector puede elegirse con todas sus entradas estrictamente positivas.

Cuadro 3: Top 20 nodos según PageRank.

Rango	ID Nodo	PageRank	d_{in}	d_{out}
1	312	0.007708	20	17
2	61	0.005693	8	0
3	105	0.005344	11	1
4	19	0.005165	7	0
5	842	0.004756	1	1
6	187	0.004476	9	18
7	578	0.004384	2	2
8	86	0.004263	10	2
9	52	0.003951	11	22
10	311	0.003874	8	4
11	38	0.003788	8	0
12	26	0.003765	9	0
13	68	0.003553	13	24
14	201	0.003347	7	7
15	306	0.003334	5	9
16	109	0.003312	12	10
17	44	0.003002	8	20
18	157	0.002941	9	12
19	89	0.002907	8	18
20	266	0.002881	7	6

4.1. Interpretación de los Nodos Más Influyentes (P7a)

Los tres nodos con mayor PageRank son **312** (0.007708), **61** (0.005693) y **105** (0.005344). El nodo 312 es plenamente consistente con la hipótesis inicial: además de tener el mayor PageRank de toda la red, también posee el mayor grado de entrada (20) y un grado de salida alto (17) —ver Cuadro 2—, lo que es coherente con un aeropuerto o centro de servicio de alto tránsito que actúa como hub principal, recibiendo y redistribuyendo tráfico hacia una gran cantidad de destinos. Un caso más interesante es el nodo 61: posee un grado de salida nulo ($out - degree = 0$, es un nodo colgante) pero aun así ocupa el puesto 2 en PageRank, con un grado de entrada moderado ($in - degree = 8$). Esto tiene mucho sentido en el contexto real: un nodo colgante en esta red representa un aeropuerto que es destino terminal de muchas rutas preferidas pero que no origina nuevas rutas hacia otros puntos. Este patrón es altamente consistente con aeropuertos de destino final de alto tráfico, contrastando con los centros de control que redistribuyen el tráfico hacia múltiples direcciones. El nodo 105 combina ambos efectos: un grado de entrada relativamente alto (11) y conexiones provenientes de nodos con buen posicionamiento, reforzando su relevancia global.

4.2. Análisis Correlacional y Anomalías Estructurales

El coeficiente de correlación de Pearson entre el grado de entrada y PageRank es de **0.7972**, indicando una relación lineal fuerte pero no perfecta. La Figura 3 muestra la dispersión de ambas medidas para todos los nodos, destacando los 10 nodos con mayor PageRank.




Figura 3: Grado de entrada vs. PageRank para todos los nodos, con los 10 nodos de mayor PageRank destacados.

Para que ambos casos se puedan comparar directamente contra la tendencia general de la red, los Cuadros 4 y 5 muestran, respectivamente, los nodos con mayor grado de entrada que peor rankean en PageRank, y los nodos con mayor PageRank cuyo grado de entrada es mínimo —tal como se obtuvieron directamente del análisis (de un total de 1226 nodos).

Cuadro 4: Nodos con alto in-degree pero PageRank relativamente bajo.

ID Nodo	PageRank	d_{in}	Rango PageRank	Rango d_{in}
46	0.001800	10	91	13
148	0.001835	9	88	21.5
73	0.001848	9	86	21.5
34	0.001975	10	78	13
116	0.001976	10	77	13

Cuadro 5: Nodos con PageRank alto pero in-degree mínimo.

ID Nodo	PageRank	d_{in}	Rango PageRank	Rango d_{in}
842	0.004756	1	5	866.5
582	0.002076	1	65	866.5
396	0.002025	1	74	866.5
418	0.001191	1	206	866.5
453	0.001159	1	215	866.5

El contraste es claro: el nodo 46 (Cuadro 4) tiene un rango de in-degree relativamente bueno (13 de 1226) que no se traduce en un buen rango de PageRank (91). El nodo 842 (Cuadro 5) muestra el patrón inverso y más extremo: el peor rango posible de in-degree (866.5, empatado con todos los nodos de grado de entrada 1) junto con uno de los mejores rangos de PageRank (5). Ambas tablas muestran, además, que este no es un caso aislado: hay varios nodos (148, 73,

34, 116 y 582, 396, 418, 453) que siguen el mismo patrón, aunque con menor intensidad. Los casos de 842 y 46 —los más representativos de cada grupo— se detallan a continuación.

El análisis revela anomalías notables que respaldan nuestra hipótesis secundaria:

- **Nodo 842 (PageRank alto, in-degree bajo):** Posee el grado de entrada mínimo posible sin estar aislado ($d_{\text{in}} = 1$), y sin embargo alcanza la posición **#5** de 1226 nodos según PageRank ($r^* \approx 0,004756$). Este nodo funciona como un puente que conecta sectores distantes del espacio aéreo nacional: su único enlace entrante proviene de un nodo con PageRank alto, por lo que hereda buena parte de esa relevancia.
- **Nodo 46 (in-degree alto, PageRank relativamente bajo):** A pesar de tener un grado de entrada elevado ($d_{\text{in}} = 10$, entre los más altos de la red), cae a la posición **#91** en PageRank ($r^* \approx 0,001800$). Sus enlaces entrantes provienen mayoritariamente de nodos periféricos con bajo PageRank propio, lo que limita su importancia global pese a su alta conectividad directa.

El subgrafo inducido por los 40 nodos principales de PageRank (Figura 4), con tamaños de nodo proporcionales a su puntuación, muestra que la red concentra la mayor parte de su flujo en un núcleo interconectado de alta jerarquía (nodos 312, 61, 105, 19, entre otros), mientras que el resto de los nodos del subgrafo se conecta principalmente hacia ese núcleo y no tanto entre sí.




Figura 4: Subgrafo inducido por los 40 nodos de mayor PageRank, con tamaño de nodo proporcional a su puntuación.

El dataset de **maayan-faa** no incluye atributos ni etiquetas adicionales por nodo (por ejemplo, región geográfica o tipo de instalación) más allá del identificador numérico interno de KONECT. Por lo tanto, no es posible analizar si los nodos de mayor PageRank pertenecen a un grupo o

categoría particular; esta ausencia de metadatos es en sí misma una limitación del análisis que se retoma en la siguiente sección.

5. Discusión, Limitaciones y Conclusiones (P8)

Veredicto sobre la hipótesis. La hipótesis planteada en P2 se cumplió **parcialmente**. Anticipamos que los nodos con mayor grado de entrada tendrían mayor PageRank, y esto se confirmó como tendencia general: el coeficiente de correlación de Pearson ($r = 0,7972$) muestra una relación fuerte entre ambas medidas, y el nodo 312 —el de mayor in-degree de toda la red— efectivamente resultó ser también el de mayor PageRank, tal como se esperaba. Sin embargo, la parte más específica de la hipótesis (la existencia de nodos de grado moderado que actúan como puentes con PageRank desproporcionadamente alto) también se confirmó, pero de forma más extrema de lo anticipado: el resultado **esperado** era encontrar algunos nodos así entre posiciones intermedias del ranking; lo **inesperado** fue que un nodo con el in-degree mínimo posible sin estar aislado ($d_{in} = 1$, nodo 842) alcanzara el puesto #5 de 1226, es decir, dentro del top-1 % de la red. Ese hallazgo es más contundente que lo que la hipótesis inicial preveía, y matiza la primera parte: el grado de entrada es un buen predictor general, pero no explica los casos más influyentes de "puente" que motivaron la pregunta de investigación.

¿La pregunta quedó respondida? Sí, en gran medida. La pregunta de investigación era si los aeropuertos con mayor tráfico entrante coinciden con los estructuralmente más relevantes, o si existen nodos de grado moderado que actúan como puentes indispensables. El coeficiente de correlación de Pearson ($r = 0,7972$) confirma que, en general, ambas cosas van de la mano: la relevancia del espacio aéreo no se reduce a contar vuelos directos, sino que refleja también la posición estratégica global dentro de la red. Sin embargo, la existencia de nodos como el 842 (in-degree mínimo, PageRank top-5) y el 46 (in-degree alto, PageRank moderado-bajo) confirma también la segunda parte de la hipótesis: el grado directo no es un predictor perfecto de importancia estructural.

Limitaciones del método y de los datos. El modelo de marcha aleatoria tiene sentido conceptual para tráfico aéreo, pero es una simplificación: asume que un «viajero» elige la siguiente ruta de forma uniforme entre las rutas salientes de un nodo, ignorando frecuencia real de vuelos, capacidad del aeropuerto o demanda de pasajeros. Los 143 nodos colgantes (11.67 %) son relativamente frecuentes y, si bien la matriz S los repara técnicamente mediante teletransportación uniforme, esto asume que desde un destino terminal se puede volver a cualquier aeropuerto de la red con igual probabilidad, lo cual no es realista. La densidad de la red (0.001741) es baja, típica de redes de transporte reales, y no impide que PageRank sea informativo, pero sí implica que unos pocos hubs concentran gran parte de la importancia relativa.

Preguntas nuevas. El análisis abrió la interrogante de qué características físicas o geográficas (no disponibles en este dataset) explican por qué ciertos nodos de bajo grado, como el 842, terminan actuando como puentes críticos; también surge la pregunta de cómo cambiaría el ranking si se incorporaran pesos de arista basados en frecuencia real de vuelos en lugar de un grafo no ponderado.

Explicación no técnica. Si tuviéramos que explicarle el resultado a alguien sin conocimientos técnicos, diríamos: no basta con contar cuántas rutas llegan directamente a un aeropuerto para saber qué tan importante es dentro del sistema; lo que realmente importa es si ese aeropuerto está conectado con otros aeropuertos que a su vez son importantes. Por eso, un aeropuerto con pocas conexiones directas puede terminar siendo clave si esas pocas conexiones lo unen a los «grandes hubs» de la red, funcionando como un punto de paso indispensable.